Лабораторная работа №2,3. Исследование факторов и организация работы с таблицами данных

Набор данных: data_purch.xlsx.

Статистика о государственных закупках лекарственных препаратов в 2021 году согласно Единой информационной системе в сфере закупок.

Информация об одной процедуре может занимать более одной строки. Если в рамках процедуры производилась закупка только одного лекарственного препарата, то такая процедура в таблице будет встречаться один раз и занимать одну строку. Если в одной процедуре содержалось n закупочных позиций, то информация об этой процедуре будет занимать в таблице n строк.

Закупка1	…	Препарат1
Закупка1	…	Препарат2
Закупка1	…	Препарат3
Закупка2	…	Препарат4
	…	

Описание полей:

first_pub_date – дата публикации процедуры,
final_protocol_pub_date – дата завершения процедуры,
purchase_number – идентификатор процедуры,
collecting_start_date – дата начала сбора заявок от потенциальных поставщиков,
collecting_end_date – дата окончания сбора заявок от потенциальных поставщиков,
placing_base_name – форма проведения торгов (конкурс, аукцион и т.п.),
cust_reg – регион заказчика процедуры,
lot_price_correct – максимально возможная, объявленная заказчиком, цена за все препараты в закупке,
drug_mnn_ext_code – идентификатор лекарственного препарата,
drug_mnn_name – наименование лекарственного препарата (их меньше, чем drug_mnn_ext_code),

drug_qty – объем закупаемого лекарственного препарата,
drug_price – цена за единицу объема закупаемого лекарственного препарата,
drug_position_price – цена за всю позицию закупаемого лекарственного препарата,
ftg – класс закупаемого лекарственного препарата,
is_abnd – фиктивная переменная: 1 – закупка не состоялась, 0 – состоялась,
is_znvlp – фиктивная переменная: 1 – в закупке содержится хотя бы 1 препарат из списка ЖВЛП, 0 – не содержатся,
is_narcotic – фиктивная переменная: 1 – в закупке содержится хотя бы 1 препарат, в составе которого есть наркотические вещества, 0 – не содержатся,
is_msp_purchase – фиктивная переменная: 1 – закупка предназначена только для субъектов малого и среднего предпринимательства, 0 – не предназначена,
is_povt – фиктивная переменная: 1 – эту процедуру заказчик вынужден повторить, 0 – не повторная,
is_dif – фиктивная переменная: 1 – в закупке содержится хотя бы 1 препарат, являющийся дефицитным, 0 – не содержатся,
app_amount_absolute_correct - сумма залога,
advance_sum_correct - сумма аванса.

Задание.

1. Скачать набор данных и проверить корректность загрузки.
2. Как вы считаете, какие из имеющихся показателей сильнее всего влияют на вероятность незакрытия закупки (закупка не состоялась)? Что еще может влиять на это, помимо представленных в наборе факторов?
3. Сформировать предложения по генерации не менее 3 новых факторов: например, связанных со временем, объемами и стоимостью позиций, их разнообразием.

   Примечание. Преобразование категориального фактора в набор фиктивных переменных считается за создание 1 нового фактора.

   Важно! Набор новых факторов во всех работах должен быть разным.
4. Сгенерировать новые факторы. По крайней мере 1 фактор должен быть получен с помощью метода главных компонент или факторного анализа, остальные – с помощью простейших арифметических операций или замен.
5. Сгруппировать исходную таблицу до структуры «одна строка – одна закупка», оставив там только те факторы, которые вы считаете релевантными. Желательно, чтобы факторов было достаточное количество.

   Примечание. В зависимости от того, как предполагается создавать новые факторы, шаги 4, 5 могут поменяться местами.

Закупка1	…	Препарат1; Препарат2; Препарат3
Закупка2	…	Препарат4

6. Выделить из полученной таблицы случайным образом выборку размера ***n*** (см. таблица). Разделить ее на обучающую и тестовую выборки в соотношении согласно варианту.
7. Провести оценку важности выделенных факторов на основе метода, указанного в таблице. Построить график, обосновать выбор наиболее важных факторов (не более 5-7).
8. На выбранных факторах построить модель логистической регрессии вероятности незакрытия закупки. Оценить ее точность на обучающей и тестовой выборке.

Варианты

№	*n*, число процедур в исходной выборке	Доля тестовой выборки	Метод в контексте оценки важности факторов
1	60 000	15%	«Случайный лес»
2	45 000	10%	Логистическая регрессия
3	75 000	5%	Дерево решений
4	50 000	20%	Линейная регрессия
5	57 000	15%	Дерево решений
6	69 000	10%	«Случайный лес»
7	72 000	5%	Дерево решений
8	80 000	20%	Логистическая регрессия
9	65 000	15%	Дерево решений
10	70 000	10%	«Случайный лес»
11	51 000	5%	Дерево решений
12	64 000	20%	«Случайный лес»
13	40 000	15%	Линейная регрессия
14	66 000	10%	Дерево решений
15	59 000	5%	«Случайный лес»
16	54 000	20%	Дерево решений
17	35 000	10%	Логистическая регрессия
18	76 000	15%	Дерево решений
19	71 000	10%	«Случайный лес»
20	67 000	5%	Дерево решений
21	55 000	20%	«Случайный лес»