Лабораторная работа №1. Кластеризация

1. Скачать набор данных согласно своему варианту. Привести описание исследуемых показателей[1].
2. Для 2 базовых показателей построить диаграмму рассеивания. Предположить, чему будет равно оптимальное число кластеров (*K*1).
3. Провести расчеты с помощью метода «локтя», построить график. Предположить, чему здесь будет равно оптимальное число кластеров (*K*2).
   Примечание: крайне желательно, чтобы *K*1 и *K*2 были разные.
4. Провести кластеризацию методом К-средних для обоих случаев (*K*1 и *K*2), рассчитать средние силуэтные коэффициенты, обосновать выбор лучшего разбиения.
5. Построить диаграмму рассеивания, на которой наблюдения из разных кластеров будут выделены соответствующими цветами, и нанесены центроиды.
6. Добавить к выборке дополнительный показатель. Разделить выборку на обучающую и прогнозную в соотношении 80%-20%.
7. С помощью метода «локтя» обосновать лучшее разбиение с учетом третьего фактора. Как изменилось это значение?
8. Провести кластеризацию на обучающей выборке. Визуально проанализировать статистическое распределение в кластерах.
9. Построить прогноз для прогнозной выборки.

Дополнительное задание.

Провести оценку точности кластеризации с помощью Acc, сравнив оценки с фактическим разбиением на группы.

Загрузка набора данных:

```
from sklearn.datasets import load_iris
data = load_iris()
# Переменная y хранится в атрибуте target
>>> data.target[[10, 25, 50]]
array([0, 0, 1])
# Классы в target

>>> list(data.target_names)
```

[1] Документация доступна по ссылке: https://scikit-learn.org/stable/datasets/toy_dataset.html#iris-plants-dataset

```
['setosa', 'versicolor', 'virginica']
# Загрузка сразу в формате фрейма
Df = load_iris(return_X_y=True, as_frame= True)
```

Варианты

№	Набор данных (функция для получения)	Базовые признаки *X*	Дополнительные признаки *X*
1	`load_iris`	sepal length in cm sepal width in cm	petal length in cm
2	`load_wine`	Alcohol Malic acid	Ash
3	`load_breast_cancer`	radius texture	perimeter
4	`load_breast_cancer`	texture area	smoothness
5	`load_breast_cancer`	perimeter smoothness	area
6	`load_iris`	sepal length in cm petal length in cm	sepal width in cm
7	`load_wine`	Alcalinity of ash Color intensity	Proanthocyanins
8	`load_breast_cancer`	smoothness area	radius
9	`load_breast_cancer`	compactness concavity	area
10	`load_wine`	Malic acid Ash	Alcalinity of ash
11	`load_breast_cancer`	concave points radius	concavity
12	`load_breast_cancer`	symmetry concavity	compactness
13	`load_wine`	Alcalinity of ash Magnesium	Total phenols
14	`load_iris`	sepal width in cm petal width in cm	sepal length in cm
15	`load_breast_cancer`	Flavanoids Nonflavanoid phenols	Proanthocyanins
16	`load_wine`	Proanthocyanins Color intensity	Hue
17	`load_iris`	petal length in cm petal width in cm	sepal width in cm
18	`load_breast_cancer`	radius fractal dimension	symmetry
19	`load_wine`	Hue OD280/OD315 of diluted wines	Proline
20	`load_iris`	sepal length in cm petal width in cm	sepal width in cm